



Técnicas de condicionamiento de modelos difusivos en CR

Diffusion Bridges en Fusión SAR-Óptica

I309 — Visión Artificial Avanzada · Otoño 2026

Universidad de San Andrés · Ingeniería en Inteligencia Artificial

Lucio Luque Materazzi

lluquematerazzi@udesa.edu.ar

Teo Manuel Kaucher

tkauc@udesa.edu.ar

Técnicas de condicionamiento de modelos difusivos en CR

Diffusion Bridges y Fusión SAR-Óptica

I309 — Visión Artificial Avanzada · Otoño 2026

Universidad de San Andrés · Ingeniería en Inteligencia Artificial

Lucio Luque Materazzi

lluquematerazzi@udesa.edu.ar

Teo Manuel Kaucher

tkaucher@udesa.edu.ar

Motivación

El Problema

- Las imágenes satelitales son clave para monitoreo ambiental, agricultura y análisis territorial.
- La nubosidad cubre una parte significativa de las capturas disponibles, reduciendo la utilidad de los datos.
- La información oculta por las nubes no está disponible en la imagen de entrada.
- Los modelos difusivos clásicos parten de ruido puro. Puede ser ineficiente si la imagen nublada ya contiene información útil.

Soluciones

SAR penetra nubes

Sentinel-1 opera con radar y captura la superficie sin importar la nubosidad.

Diffusion Bridge

Modela una trayectoria directa: de imagen nublada a imagen limpia, sin partir de ruido puro.

Fusión multimodal

Utilizar un método que aproveche la combinación de información SAR y óptica.

Dataset — SEN12MSCR — Muestras

Cada muestra es un triplete de imágenes de 256×256 píxeles: 2 canales de Sentinel-1, 13 de Sentinel-2.



SAR — Sentinel-1





Imagen Nublada — Sentinel-2



Imagen Limpia (target) — Sentinel-2



Dataset — SEN12MSCR — Conjunto

175


ROIs globales

122.218

tripletes totales

272 GB

comprimido



Dataset — SEN12MSCR — Preprocesamiento

175

ROIs globales

122.218

tripletes totales

272 GB

comprimido



16



ROIs (Sudamérica)

11.084

tripletes utilizados

41 GB

tamaño final



Canales utilizados

6

en la mayoría

13

en un experimento

Partición del dataset en ROIs

12

de entrenamiento

4

de test

Marco Teórico — Entrenamiento e inferencia

Difusión clásica (DDPM)

Proceso de ruido gaussiano progresivo. El modelo aprende a revertir el ruido paso a paso.

Algorithm 1 Entrenamiento de DDPM condicional

Require: Imagen nublada $\mathbf{x}$, imagen limpia $\mathbf{y}_0$, scheduler de ruido, modelo f_θ

- 1: Muestrear un paso temporal $t \sim \mathcal{U}(1, T)$
- 2: Muestrear ruido gaussiano $\epsilon \sim \mathcal{N}(0, I)$
- 3: Obtener la imagen ruidosa con el valor acumulado $\bar{\alpha}_t$:

$$\mathbf{y}_t = \sqrt{\bar{\alpha}_t} \mathbf{y}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$$

- 4: Predecir el ruido:

$$\hat{\epsilon} = f_\theta(\mathbf{y}_t, t, \mathbf{x})$$

- 5: Calcular la pérdida:

$$\mathcal{L} = \|\epsilon - \hat{\epsilon}\|_2^2$$

- 6: Actualizar los parámetros de f_θ mediante descenso por gradiente

Algorithm 2 Inferencia de DDPM condicional

Require: Imagen nublada $\mathbf{x}$, scheduler de ruido, modelo entrenado f_θ , cantidad de pasos de inferencia N


- 1: Inicializar $\mathbf{y}_T \sim \mathcal{N}(0, I)$
- 2: Definir los pasos temporales de inferencia con el scheduler
- 3: **for** cada paso temporal t desde T hasta 0 **do**
- 4: Predecir el ruido en la muestra actual:

$$\hat{\epsilon} = f_\theta(\mathbf{y}_t, t, \mathbf{x})$$

- 5: Actualizar la muestra mediante el paso inverso del scheduler:

$$\mathbf{y}_{t-1} = \text{SchedulerStep}(\mathbf{y}_t, \hat{\epsilon}, t)$$

- 6: **end for**
- 7: Retornar $\hat{\mathbf{y}}_0$



Marco Teórico — Entrenamiento e inferencia

Diffusion Bridge (DB-CR)

Puente directo entre la distribución de imágenes nubladas y la distribución limpia. Sin ruido puro.

Algorithm 3 Entrenamiento de DB-CR

Require: Imagen nublada $\mathbf{x}$, imagen limpia $\mathbf{y}_0$, scheduler de ruido, modelo f_θ

- 1: Muestrear un paso temporal $t \sim \mathcal{U}(1, T)$
- 2: Calcular el coeficiente del puente λ_t
- 3: Construir la muestra intermedia:

$$\mathbf{x}_t = (1 - \lambda_t)\mathbf{y}_0 + \lambda_t\mathbf{x}$$

- 4: Predecir la imagen limpia:

$$\hat{\mathbf{y}}_0 = f_\theta(\mathbf{x}_t, t, \mathbf{x})$$

- 5: Calcular la pérdida:

$$\mathcal{L} = \|\mathbf{y}_0 - \hat{\mathbf{y}}_0\|_1$$

- 6: Actualizar los parámetros de f_θ mediante descenso por gradiente

Algorithm 4 Inferencia de DB-CR

Require: Imagen nublada $\mathbf{x}$, modelo entrenado f_θ , scheduler de ruido, cantidad de pasos N


- 1: Inicializar $\mathbf{x}_T = \mathbf{x}$
- 2: Definir una secuencia descendente de pasos temporales desde T hasta 1
- 3: **for** cada paso temporal t **do**
- 4: Predecir la imagen limpia:

$$\hat{\mathbf{y}}_0 = f_\theta(\mathbf{x}_t, t, \mathbf{x})$$

- 5: Calcular el paso temporal anterior t'
- 6: Calcular el coeficiente $\lambda_{t'}$
- 7: Actualizar el estado del puente:

$$\mathbf{x}_{t'} = (1 - \lambda_{t'})\hat{\mathbf{y}}_0 + \lambda_{t'}\mathbf{x}$$

- 8: **end for**
- 9: Retornar $\hat{\mathbf{y}}_0$




Arquitecturas Implementadas

Sin SAR

DDPM Condicional

Diffusion clásica desde ruido puro

U-Net con bloques residuales. La imagen nublada condiciona el proceso. Referencia baseline.





Arquitecturas Implementadas

Sin SAR

DBCR-S (Simple)

Diffusion Bridge
sin información SAR
Bloques NAFT

U-Net con bloques NAFT
(Nonlinear Activation Free
with Time embedding).



SAR concat

DBCR-SC

SAR concatenado
a la imagen original
+2 canales

Estrategia más simple de
fusión SAR. Bajo costo
arquitectónico. Evaluada con
y sin transfer learning.


Arquitecturas Implementadas

SAR ControlNet

DBCR-SCN

Rama auxiliar tipo ControlNet para SAR

Rama paralela para SAR, inyecta features en distintos niveles. Se parte desde DBCR-S congelado y se entrena la rama ControlNet.





Arquitecturas Implementadas

SAR con SARFs

DBCR (completo)

Bloques SARF
atención cruzada
SAR-Óptico multiescala

Arquitectura más compleja con Attention.
Optimizaciones utilizadas:
Window attention 8×8 en SARF Block 1, con gradient checkpointing, flash attention y autocast en todas las capas.
Para este modelo se entrenaron dos versiones: una utilizando los 6 canales y otra con los 13 totales.



Métricas de Evaluación

MAE

↓ menor es mejor

$$\frac{1}{m \cdot n \cdot c} \sum_{i,j,k} |I(i,j,k) - K(i,j,k)|$$

Error Absoluto Medio. Mide la diferencia punto a punto entre imagen predicha y real. También se usa como función de pérdida durante el entrenamiento.

PSNR

↑ mayor es mejor

$$10 \cdot \log_{10} \left(\frac{\text{MAX}_I^2}{\text{MSE}} \right)$$

Peak Signal-to-Noise Ratio en dB. Estima la relación entre la señal máxima posible y el ruido de la reconstrucción. Valores altos indican mayor similitud global.

SSIM

↑ mayor es mejor

$$\frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}$$

Structural Similarity Index. Cuantifica similitud estructural considerando luminancia, contraste y estructura. Más perceptualmente informativo que MAE/PSNR.

SAM

↓ menor es mejor

$$\frac{1}{m \cdot n} \sum_{i,j} \arccos \left(\frac{I(i,j) \cdot K(i,j)}{\|I(i,j)\| \|K(i,j)\|} \right)$$

Spectral Angle Mapper en grados. Mide la similitud espectral entre vectores de bandas por píxel. Especialmente relevante para imágenes multiespectrales como Sentinel-2.

Resultados — Sin Información SAR

Modelo	Épocas	PSNR ↑	SSIM ↑	MAE ↓	SAM ↓
DDPM condicional	15	16.19	0.311	0.1293	49.40
DDPM condicional	30	18.46	0.180	0.1046	48.51
DBCR-S	15	27.58	0.807	0.0313	12.78
DBCR-S	30	26.70	0.798	0.0339	11.13

Conclusión 1

DBCR-S supera al DDPM en todas las métricas con solo 15 épocas. El DDPM requeriría muchas más iteraciones porque parte de ruido puro, no de la imagen nublada.

Conclusión 2

El SSIM del DDPM empeora al pasar de 15 a 30 épocas (0.311 → 0.180), indicando inestabilidad. DBCR-S satura tempranamente: más épocas mejoran SAM pero no PSNR/SSIM.

Resultados — Con información SAR

Modelo	Épocas	PSNR ↑	SSIM ↑	MAE ↓	SAM ↓
DBCR-S (Sin SAR)	15	27.58	0.807	0.0313	11.13
DBCR-SC (concat, TL)	15	26.78	0.792	0.0343	10.71
DBCR-SC (concat)	30	27.82	0.801	0.0287	9.81
DBCR-SCN (ControlNet)	15	27.28	0.780	0.0320	11.05
DBCR — 6 canales ★	60	28.45	0.840	0.0274	9.82
DBCR — 13 canales	30	27.21	0.834	0.0293	10.89

Conclusiones

- DBCR-SC con TL y DBCR-SCN no superan a DBCR-S (desde donde partieron), lo que indica que adaptar un modelo preentrenado podría requerir una cantidad mucho mayor de épocas para mostrar mejoras.
- DBCR-SC sin TL sí supera a DBCR-S, lo que podría indicar que contar con los datos de condicionamiento desde el comienzo puede resultar en mejores métricas.
- Siguiendo con esta idea, DBCR con 6 canales logra los mejores resultados, resaltando el potencial del SARF Block.
- Finalmente, se ve que usar los 13 canales no es la mejor opción. Podría indicar que los 7 canales adicionales tienen una baja correlación con el problema y entorpecen al modelo.



Resultados — Benchmarking

Method	MAE ↓	SAM ↓	PSNR ↑	SSIM ↑
McGAN (Enomoto et al., 2017)	0,048	15,676	25,14	0,744
SAR-Opt-cGAN (Grohnfeldt et al., 2018)	0,043	15,494	25,59	0,764
SAR2OPT (Bermudez et al., 2018)	0,042	14,788	25,87	0,793
SpA GAN (Pan, 2020)	0,045	18,085	24,78	0,754
Simulation-Fusion GAN (Gao et al., 2020)	0,045	16,633	24,73	0,701
DSen2-CR (Meraner et al., 2020)	0,031	9,472	27,76	0,874
GLF-CR (Xu et al., 2022)	0,028	8,981	28,64	0,885
UnCRtainTS L2 (Ebel et al., 2023)	0,027	8,320	28,90	0,880
ACA-Net (Huang et al., 2024)	0,025	7,770	29,78	0,896
DiffCR (Zou et al., 2024)	0,019	5,821	31,77	0,902
EMRDM (Liu et al., 2025)	0,018	5,267	32,14	0,924
ECRformer-Light (Zhang et al., 2026)	0,018	5,026	32,75	0,920
DB-CR (Hu et al., 2025)	0,016	4,740	33,47	0,922
ECRformer (Zhang et al., 2026)	0,016	4,693	33,37	0,932

Resultados — Benchmarking

Method	MAE ↓	SAM ↓	PSNR ↑	SSIM ↑
McGAN (Enomoto et al., 2017)	0,048	15,676	25,14	0,744
SAR-Opt-cGAN (Grohnfeldt et al., 2018)	0,043	15,494	25,59	0,764
SAR2OPT (Bermudez et al., 2018)	0,042	14,788	25,87	0,793
SpA GAN (Pan, 2020)	0,045	18,085	24,78	0,754
Simulation-Fusion GAN (Gao et al., 2020)	0,045	16,633	24,73	0,701
DSen2-CR (Meraner et al., 2020)	0,031	9,472	27,76	0,874
DBCR — 6 canales ★	0,027	9,820	28,45	0,840
GLF-CR (Xu et al., 2022)	0,028	8,981	28,64	0,885
UnCRtainTS L2 (Ebel et al., 2023)	0,027	8,320	28,90	0,880
ACA-Net (Huang et al., 2024)	0,025	7,770	29,78	0,896
DiffCR (Zou et al., 2024)	0,019	5,821	31,77	0,902
EMRDM (Liu et al., 2025)	0,018	5,267	32,14	0,924
ECRformer-Light (Zhang et al., 2026)	0,018	5,026	32,75	0,920
DB-CR (Hu et al., 2025)	0,016	4,740	33,47	0,922
ECRformer (Zhang et al., 2026)	0,016	4,693	33,37	0,932

Resultados — Visualización



Conclusiones

01

Diffusion Bridge > DDPM

El Diffusion Bridge supera ampliamente al DDPM clásico. Partir de la imagen nublada (no de ruido puro) aprovecha mejor la información disponible en el input.

02

SAR mejora el espectro

La incorporación de SAR permite conseguir información no observable detrás de las nubes, mejorando todas las métricas cuando se integra de manera inteligente.

03

Concatenación > ControlNet

La estrategia más simple (DBCR-SC sin TL) supera a ControlNet. Condicionar la red desde un principio consigue mejores resultados que condicionar una versión congelada.

04

Atención cruzada gana

DBCR completo con bloques SARF logra el mejor PSNR/SSIM (28.45 / 0.840). La fusión multiescala SAR–óptico por atención cruzada es la estrategia más efectiva.

Trabajo Futuro

1

Estudios con entrenamiento completo

Utilizar el dataset completo, hacer data augmentation y entrenar con más pasos de inferencia.

2

Búsqueda de hiperparámetros

Búsqueda más exhaustiva de hiperparámetros de red (canales, profundidad) y de entrenamiento (learning rate, scheduler, batch size).

3

Perceptual Loss (VGG-19)

Realizar experimentos con pérdidas perceptuales basadas en VGG-19 para mejorar la calidad visual percibida más allá de las métricas MAE/PSNR/SSIM.

4

Mejoras de attention

Reemplazar Window Attention por alternativas más eficientes, como Neighbor Attention, Deformable Attention o Linear Attention.

iGracias!

Lucio Luque Materazzi · lluquematerazzi@udesa.edu.ar

Teo Manuel Kaucher · tkaucher@udesa.edu.ar

I309 — Visión Artificial Avanzada · Universidad de San Andrés · Otoño 2026